



PERANCANGAN SISTEM DETEKSI DINI GEMPA BUMI BERBASIS RESIDUAL NEURAL NETWORK UNTUK ESTIMASI MAGNITUDO

Jordan Arya Leksana

5009221116

Dosen Pembimbing :

Dr. Bambang L. Widjiantoro, S.T., M.T.


196905071995121001

Pendahuluan




Gempa bumi dapat menyebabkan **kerusakan infrastruktur, korban jiwa, tsunami, dan kerugian ekonomi.**

(BMKG, 2022)



Anomali ULF
diinterpretasikan
sebagai indikator tidak
langsung dari proses
persiapan gempa di
zona seismogenik.

(Hattori and Hayakawa, 2004).



Rumusan Masalah

1

Bagaimana pemodelan deep learning berbasis arsitektur Residual Neural Network (ResNet) dapat digunakan untuk mengenali pola prekursor gempa bumi ?

2

Bagaimana arsitektur ResNet dapat digunakan untuk mengestimasi magnitudo gempa bumi secara robust dalam kondisi data yang kompleks dan mengandung noise?

Tujuan

1

Mengembangkan model deep learning berbasis Residual Neural Network (ResNet) dengan pendekatan multitask learning yang terdiri dari dua head untuk secara simultan mengekstraksi fitur spasial dan temporal dari data geofisika serta mengestimasi parameter gempa bumi.

2

Menerapkan dan mengevaluasi kinerja model multitask dalam menangkap pola precursor dan mengestimasi magnitude gempa dari data yang mengandung variasi tingkat kebisingan dan gangguan eksternal, ditinjau dari akurasi, konsistensi, dan ketahanan model.

Batasan Masalah

1

Data yang digunakan dalam penelitian ini terbatas pada data magnet bumi (geomagnetik) yang diperoleh dari jaringan pengamatan **MAGDAS (Magnetic Data Acquisition System)** yang dioperasikan oleh Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) di wilayah Indonesia periode tahun **2018 hingga 2025**.

2

Penelitian ini dibatasi pada **pengembangan dan evaluasi** model berbasis deep learning menggunakan arsitektur Residual Neural Network (ResNet) dengan pendekatan multitask learning untuk **keperluan estimasi magnitudo gempa serta identifikasi prekursor gempa**.


Manfaat


1

Bagi pengembangan ilmu pengetahuan, penelitian ini memberikan kontribusi berupa pendekatan baru dalam pemanfaatan **arsitektur Residual Neural Network (ResNet)** dengan **skema multitask learning** untuk mengekstraksi pola prekursor gempa dari sinyal geomagnetik ULF serta mengestimasi magnitude gempa.


2

Bagi institusi dan praktik mitigasi, hasil penelitian dapat menjadi dasar pengembangan komponen sistem pendeteksian dini gempa berbasis **data geomagnetik MAGDAS-BMKG** yang lebih cepat dan robust terhadap noise, sehingga berpotensi mendukung penguatan sistem peringatan dini yang sudah ada.





Sinyal Ultra Low Frequency (ULF) berada pada **bagian frekuensi paling rendah**, sehingga memiliki **panjang gelombang yang sangat besar**.



Anomali ULF

Pulsations	T, s	f	Amplitudes, nT
Pc 1	0.2–5	0.2–5 Hz	0.01–0.1
Pc 2	5–10	0.1–0.2 Hz	0.1–1
Pc 3	10–45	22–100 mHz	1–10
Pc 4	45–150	7–22 mHz	5–50
Pc 5	150–600	2–7 mHz	50–500
Pi 1	1–40	0.025–1 Hz	0.2–1
Pi 2	40–150	2–25 mHz	10–100

Dipilih Pita **Pc3** karena pita ini masih berada dalam rentang ULF yang memiliki zona yang **relevan untuk pengamatan fenomena pre-seismic pada sinyal ULF**.


(Molchanov and Hayakawa, 2008)

Anomali ULF

Aktivitas di dalam litosfer pada pra gempa dapat **memicu perubahan fisik pada batuan.**


**Mekanisme
Lithosphere-Atmosphere-Ionosphere Coupling (LAI Coupling)**

Objek Penelitian




*kondisi khusus yang diasumsikan terjadi ketika ada aktivitas seismik atau proses persiapan gempa

Anomali ULF



Distribusi aktivitas geomagnetik ULF dan aktivitas seismik terhadap frekuensi (Uyeda et al., 2009)

Hubungan Magnitudo



*hubungan antara magnitudo gempa, jarak episenter, dan peluang munculnya anomali ULF.

Anomali ULF tidak hanya dipengaruhi oleh adanya gempa, tetapi juga oleh besar magnitudo dan jarak antara episenter gempa dengan stasiun pengamatan.

Ambang empiris

$$0.025R \leq M - 4.5$$

R = jarak episentral (km)
M = magnitudo gempa

Interpretasi

Semakin besar magnitudo gempa, semakin besar peluang anomali ULF terdeteksi pada jarak yang lebih jauh.

Model sederhana

$$M = A \cdot X + R \cdot Y + C$$


A = amplitudo sinyal, R = jarak
X, Y, C = parameter kalibrasi

Implikasi untuk model:

pola ULF dapat menjadi indikator tidak langsung bagi model untuk mempelajari kelas magnitudo.

Hubungan ini dapat menjadi fitur/informasi bagi model untuk mengestimasi kelas magnitudo.

Residual Net




ResNet memperkenalkan **konsep residual learning**, yaitu pembelajaran fungsi perubahan (residual) terhadap input sebelumnya (He et al., 2016).

sehingga model tidak harus mempelajari transformasi penuh, tetapi cukup mempelajari selisih dari layer sebelumnya..

CNN, $Y = H(x)$

Bisa untuk mempelajari sinyal geomagnetik yang memiliki **pola kompleks, tidak menentu, dan mengandung noise**.

50 layers	$cfg=[3,4,6,3]$
101 layers	$cfg=[3,4,23,8]$
152 layers	$cfg=[3,8,36,3]$



Predicted Class


Confusion Matrix

Evaluasi Model

		Predicted Class			
		Positive	Negative		
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	True Positive Rate, Hit Rate, Sensitivity, Recall $\frac{TP}{(TP + FN)}$	False Negative Rate, True Omission Rate, Type II Error Rate, Miss Rate $\frac{FN}{(FN + TP)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	True Negative Rate, Specificity $\frac{TN}{(TN + FP)}$	False Positive Rate, Fallout Rate, Type I Error Rate $\frac{FP}{(FP + TN)}$
		Positive Predictive Value, Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value, False Omission Rate $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$	Error Rate $\frac{FP + FN}{(TP + TN + FP + FN)}$
		F1 Score = $2 * \frac{(\text{Precision} * \text{Recall})}{(\text{Precision} + \text{Recall})}$			

Pada Penelitian ini Karena basis nya adalah klasifikasi jadi digunakan **metrik klasifikasi** dan **confusion matrix** sebagai bahan evaluasi dari model


Flowchart Penelitian



Pengumpulan data


Data Katalog Gempa 2018-2025 dengan total **25.783** kejadian gempa

EventID	datetime	Latitude	Longitude	Magnitude	Depth	MagType	Location
bmg2025zpbp	2025-12-30 23:58:10.111335+00:00	4.73421573638916	96.793358021972656	2.9705346411119683	5.0	MLv	Northern Sumatra, Indonesia
bmg2025zapr	2025-12-30 23:46:37.900589+00:00	3.16050386428833	128.0780792236328	3.458470168102622	5.0	MLv	North of Halmahera, Indonesia
bmg2025zoyj	2025-12-30 22:36:10.818835+00:00	2.9888356971740723	128.92593833789862	4.0315553899232817	8.0	MLv	Halmahera, Indonesia
bmg2025zowu	2025-12-30 21:48:38.624128+00:00	0.2523478818996429	119.68063354492188	2.159850748264372	21.0	MLv	Minahassa Peninsula, Sulawesi
bmg2025zowa	2025-12-30 20:55:10.413732+00:00	1.2793054580688477	123.21712089507812	4.404368110314564	23.0	MLv	Minahassa Peninsula, Sulawesi
bmg2025zoty	2025-12-30 20:19:21.579390+00:00	-2.5031981468200684	127.44911760253906	3.909391743252786	4.0	MLv	Ceram Sea
bmg2025zott	2025-12-30 20:16:56.751632+00:00	-7.305625438690186	106.89063262939452	2.444171010946819	110.0	MLv	Java, Indonesia
bmg2025zotn	2025-12-30 20:14:07.479995+00:00	-8.2316589527488207	117.75828552246094	2.333120262917279	4.0	MLv	Sumbawa Region, Indonesia
bmg2025zots	2025-12-30 20:08:10.389856+00:00	-5.675173282623291	128.9076690673828	3.5616504975080183	117.0	MLv	Seram, Indonesia
bmg2025zovr	2025-12-30 19:40:11.862580+00:00	-8.643149375915527	119.6031951904297	2.949533591629964	130.0	MLv	Flores Region, Indonesia
bmg2025zowr	2025-12-30 19:18:11.159446+00:00	0.1879117637872696	121.0573272705078	2.492360426600067	83.0	MLv	Minahassa Peninsula, Sulawesi
bmg2025zony	2025-12-30 18:47:46.552204+00:00	1.0036245554487915	122.8315687451172	1.49488228480661825	31.0	MLv	Minahassa Peninsula, Sulawesi
bmg2025zupu	2025-12-30 18:37:30.038660+00:00	3.3523897064685821	122.59754180908205	2.0282194941994523	88.0	MLv	Minahassa Peninsula, Sulawesi
bmg2025zoqm	2025-12-30 18:33:24.554369+00:00	-9.58846378326416	119.41179656982422	2.2616425432147964	5.0	MLv	Sumba Region, Indonesia
bmg2025zopn	2025-12-30 18:16:07.684518+00:00	4.127608776092528	97.37126822607422	2.585549902345496	3.0	MLv	Northern Sumatra, Indonesia
bmg2025zopf	2025-12-30 18:10:33.551523+00:00	-8.882755279541016	124.2438201904297	1.877611204234713	73.0	MLv	Timor Region
bmg2025zopi	2025-12-30 18:10:33.464681+00:00	4.737986566463623	96.7665537613128	2.1259551339538055	4.0	MLv	Northern Sumatra, Indonesia
bmg2025zopk	2025-12-30 18:02:29.185509+00:00	-4.2085815865981445	97.38970184326172	2.0426066049319904	10.0	MLv	Northern Sumatra, Indonesia
bmg2025zoni	2025-12-30 17:57:44.739909+00:00	-0.33798320718040466	132.84499669024658	2.4015982844606173	9.0	MLv	West Papua Region, Indonesia
bmg2025zoni	2025-12-30 17:50:04.141948+00:00	-0.621622622013092	131.8197784423828	2.4156289588860366	7.0	MLv	West Papua Region, Indonesia
bmg2025zonm	2025-12-30 17:13:33.055467+00:00	4.63122558593375	96.2890625	2.2406880526467467	6.0	MLv	Northern Sumatra, Indonesia
bmg2025zonn	2025-12-30 17:06:38.959430+00:00	-8.298652648925781	119.6604232788086	3.5999233715932037	164.0	MLv	Flores Region, Indonesia
bmg2025zonp	2025-12-30 17:01:51.101630+00:00	-5.5316758155822754	140.27236939476562	3.760677583078047	13.0	MLv	West Papua, Indonesia
bmg2025zonb	2025-12-30 16:38:00.462644+00:00	-3.750121593375342	134.70994567871094	3.155637846915165	13.0	MLv	West Papua Region, Indonesia
bmg2025zonk	2025-12-30 16:11:06.498847+00:00	1.0932466983795166	126.2499868505856	2.6099889759343326	21.0	MLv	Northern Molucca Sea
bmg2025zonk	2025-12-30 16:04:50.672397+00:00	4.780135685235596	96.74430824228516	2.559128459886408	4.0	MLv	Northern Sumatra, Indonesia
bmg2025zonk	2025-12-30 15:43:42.110198+00:00	4.733952522277832	96.76598701904295	2.5412388426859334	25.0	MLv	Northern Sumatra, Indonesia
bmg2025zonh	2025-12-30 15:35:36.550991+00:00	-8.95892620849667	112.44883197021484	3.258095349603277	25.0	MLv	Java, Indonesia
bmg2025zonk	2025-12-30 15:33:44.444660+00:00	4.73130989074707	96.76894323766211	3.175958402187093	5.0	MLv	Northern Sumatra, Indonesia



Diambil **top 3** stasiun dari masing masing **Event Gempa**.

```
def _top_k(self, row, k):
    dists = sorted([
        (self.haversine(row["Latitude"], row["Longitude"], lat, lon), name)
        for (lat, lon), name in zip(self._coords, self._names)
    ])
    return [n for _, n in dists[:k]]
```



$$d = 2R \cdot \arcsin \left(\sqrt{\sin^2 \left(\frac{\Delta\varphi}{2} \right) + \cos \varphi_1 \cos \varphi_2 \sin^2 \left(\frac{\Delta\lambda}{2} \right)} \right)$$

d = jarak episentrum-stasiun (km)
 R = jari-jari Bumi = 6371 km
 φ = latitude (radians), λ = longitude (radians)

Pembacaan Sensor Magnetometer

Data sensor magnetometer diambil **secara aman dan sudah dapat izin** dari server BMKG melalui **koneksi SSH dan SFTP**.

Format data sensor

No	Field	Tipe Data	Ukuran
1	Hcomp	float32	4 byte
2	Dcomp	float32	4 byte
3	Zcomp	float32	4 byte
4	IXcomp	float32	4 byte
5	IYcomp	float32	4 byte
6	TempS	float32	4 byte
7	TempP	float32	4 byte
8	Voltage	float32	4 byte

Header = 32 byte | Record = 17 byte | 86.400 sampel/hari

Akses data server

```
precursor@server:~$ ls ./SEISMO/DATA/ALR/SData/2401/
Format 1AAGA/      S240116.ALAR  S240121.ALAR
S240114.ALAR.gz   S240117.ALAR.gz S240122.ALAR.gz
S240115.ALAR      S240118.ALAR  S240124.ALAR
```

Station baselines

Stasiun	Komp.	Baseline
GT0, GSI, TND	H	40000
GT0, GSI, TND	Z	30000
Lainnya	H	38000
Lainnya	Z	32000

Data conversion

```
Hcomp = baseline["H"] + h * 0.1
Dcomp = d * 0.1
Zcomp = baseline["Z"] + z * 0.1
IXcomp = ix * 0.01
IYcomp = iy * 0.01
TempS = temps * 0.1
TempP = temp * 0.1
Voltage = volt * 0.01
```

nilai mentah → besaran fisik


Data magnetometer yang tersimpan masih berupa nilai **deviasi/offset mentah dari sensor**, sehingga perlu dikembalikan ke **nilai fisik komponen geomagnetik** berdasarkan referensi baseline tiap stasiun

kaidah konversinya mengikuti format **rekaman biner sensor** di mana setiap field raw dikalikan faktor skala tertentu

Fungsi utama pembacaan binary

```
def _parse_binary(raw, year, month, day, station):
    baseline = STATION_BASELINES.get(station, DEFAULT_BASELINE)
    body = raw[Config.HEADER_SIZE:]
    n_rec = min(86400, len(body)) // Config.RECORD_SIZE
    p = np.frombuffer(body[:n_rec * Config.RECORD_SIZE], dtype=dtype)
    return out
```

Fungsi membaca data harian stasiun, mem-parse record binary, lalu mengembalikan dictionary kanal sensor.




HDZ to XYZ

Transformasi XYZ & Filter PC3

Filter PC3


Filter PC3 berfungsi untuk **hanya meloloskan frekuensi** yang berada pada rentang Pc3:

0.022 Hz - 0.1 Hz




Agar informasi horizontal lebih mudah dipelajari oleh model, **keduanya diubah menjadi dua komponen ortogonal, yaitu X dan Y.**

Geomagnetic Components HDZ - Raw + PC3 Filtered | KPY | 2024-06-01




Geomagnetic Components XYZ - Raw + PC3 Filtered | KPY | 2024-06-01



Filter Hari

Pemilihan hari dilakukan secara acak dengan rentang **H-30** hingga hari **H gempa bumi** terjadi. Dengan tambahan **Filter Disturbance Storm Time (DST)**

No.	Kategori Badai	Rentang DST (nT)
1	Weak	$-30 \geq \text{Dst} > -50$
2	Moderate	$-50 \geq \text{Dst} > -100$
3	Strong	$-100 \geq \text{Dst} > -200$
4	Very Strong	$-200 \geq \text{Dst} > -300$
5	Super	$\text{Dst} \leq -300$



Sumber Data DST (Real-Time):


<https://wdc.kugi.kyoto-u.ac.jp/>

Pemilihan Hari dan Jam

Filter Jam

Hasil Filter Hari akan diambil Jam dengan hasil varians Terbesar adanya penyebaran nilai yang lebih besar dari data normal sebagai indikasi adanya **Anomali prekursor**

Data pada tanggal 1 Juni 2024 stasiun KPY Jam 12.00




Kaidah

Nilai Magnitude	Label
$M = 0$	Normal
$4.5 < M < 5.0$	Moderate
$5.0 \leq M < 6.0$	Medium
$M \geq 6.0$	Large

```
def __init__(self, catalog_path, station_path):  
    self.df = pd.read_csv([catalog_path])  
    self.df["Magnitude_class"] = self.df["Magnitude"].apply(self._classify_mag)  
  
    @staticmethod  
    def _classify_mag(m):  
        if m < 5.0: return "Moderate"  
        if m < 6.0: return "Medium"  
        return "Large"
```

Hasil


Pelabelan Kelas




Hasil

Pelabelan Kelas

Moderate | Raw XYZ + PC3 Filtered | KPY | 2024-06-01 | H19 | M=4.62




Medium | Raw XYZ + PC3 Filtered | LPS | 2022-02-23 | H01 | M=5.21




Hasil

Pelabelan Kelas



Transformasi Scalogram

Hasil




Transformasi CWT digunakan untuk merepresentasikan sinyal geomagnetik XYZ ke dalam **domain waktu-frekuensi**

Continuous Wavelet (cmor1.5-1.0)
Frekuensi Sampling = 1Hz
Scales Adaptif


Hasil

Transformasi Scalogram

Medium | XYZ PC3 + CMOR CWT | LPS | 2022-02-23 | H01 | M=5.21




Large | XYZ PC3 + CMOR CWT | KPY | 2022-08-26 | H01 | M=6.22




Hasil Global log z-score

Transformasi Scalogram

Normal | XYZ Scalogram After Loader | log_global_zscore | TRD | 2020-11-15 | H19 | M=0.00




Moderate | XYZ Scalogram After Loader | log_global_zscore | KPY | 2024-06-01 | H19 | M=4.62




Hasil Global log z-score

Transformasi Scalogram


Medium | XYZ Scalogram After Loader | log_global_zscore | LPS | 2022-02-23 | H01 | M=5.21



Large | XYZ Scalogram After Loader | log_global_zscore | KPY | 2022-08-26 | H01 | M=6.22




Hasil




Visualisasi distribusi **jumlah sampel setiap kelas** pada data train, validation, dan test 2025.

Rangkuman Dataset



Perbandingan **jumlah sampel pada setiap stasiun pengamatan** untuk data train periode 2018-2024 dan data test tahun 2025.

Arsitektur Model




Parameter	Nilai
Epoch	150
Batch Size	16
Learning Rate	1×10^{-5}
Weight Decay	1×10^{-5}
Device	Cuda

Semua Konfigurasi didasarkan pada **Trial n Error** & Menyesuaikan envirointment device: **GeForce RTX 5070** dengan **12 GB VRAM**, memori GDDR7, dan CUDA cores 6144 dan shared memory 32 GB, serta berjalan pada operating system linux Ubuntu 24.0.1.

Hasil Train dan Test Prekursor


Training and Validation Precursor Accuracy



Hasil deteksi

Test 2025


Metrik	Nilai
Accuracy	0,8825
Macro F1	0,8824




Analisis GradCam Prekursor vs Non Prekursor

Hasil deteksi


Hasil Analisis Grad-CAM pada data validasi non-prekursor tanggal 3 Maret 2019 01:00 UTC di Stasiun SBG




Hasil Analisis Grad-CAM pada data validasi prekursor tanggal 1 Januari 2025 12:00 UTC di Stasiun LWA




Hasil Analisis Grad-CAM pada data validasi prekursor tanggal 1 Januari 2025 12:00 UTC di Stasiun LWA



Hasil Analisis Grad-CAM pada data validasi prekursor tanggal 1 Januari 2025 12:00 UTC di Stasiun SCN




Hasil Train dan Test Magnitudo



Hasil deteksi

Test 2025


Metrik	Nilai
Accuracy	0,5267
Macro F1	0,3253




Analisis GradCam Prediksi Magnitudo Kelas Large

Hasil deteksi


Hasil Analisis Grad-CAM Magnitude pada data validasi prekursor kejadian eq_48801 tanggal 25 Januari 2019 di Stasiun LWA dengan kelas Large yang terprediksi oleh model




Hasil Analisis Grad-CAM Magnitude pada data validasi prekursor kejadian eq_62245 tanggal 10 Oktober 2020 di Stasiun LWA dengan kelas Large yang terprediksi oleh model



**Hasil Analisis Grad-CAM Magnitude pada data validasi prekursor kejadian eq_62245 tanggal 10 Oktober 2020
di Stasiun LWA dengan kelas Large yang terprediksi oleh model**



**Hasil Analisis Grad-CAM Magnitude pada data validasi prekursor kejadian eq_62245 tanggal 10 Oktober 2020 di
Stasiun KPY dengan kelas Large yang terprediksi oleh model**



Kesimpulan

1

Model multi-task yang dibangun menunjukkan **kemampuan yang baik dalam mendeteksi keberadaan prekursor gempa bumi**. Pada tugas deteksi prekursor, model memperoleh **akurasi sebesar 88,25%**. Hasil ini menunjukkan bahwa representasi **scalogram dari sinyal ULF** mampu merepresentasikan **pola pembeda antara kelas prekursor dan non-prekursor secara konsisten**, diperkuat oleh hasil **interpretasi Grad-CAM**, yang menunjukkan **area aktivasi model cenderung stabil dan konsisten pada beberapa stasiun pengamatan**.

2

Pada tugas estimasi magnitudo, **model mampu mengklasifikasikan gempa ke dalam tiga kelas magnitudo**, yaitu Moderate, Medium, dan Large, dengan **akurasi sebesar 52,67%**. Hasil analisis menunjukkan bahwa performa yang masih terbatas tersebut dipengaruhi oleh **ketidakseimbangan distribusi data antar-kelas** serta **belum kuatnya hubungan langsung antara amplitudo anomali geomagnetik dan magnitudo gempa**. Kondisi ini juga terlihat dari visualisasi Grad-CAM, di mana **area aktivasi model cenderung berubah-ubah pada setiap kejadian**.

Saran

1

Mengembangkan model agar tidak hanya mengestimasi precursor dan magnitudo, tetapi juga **arah datang gempa (azimuth)**, sehingga estimasi parameter gempa menjadi lebih lengkap untuk kebutuhan peringatan dini.

2

Meningkatkan akurasi estimasi magnitudo, antara lain melalui **penanganan ketimpangan kelas** (misalnya class weighting, focal loss, atau penambahan sampel data pada rentang dibawah 2018) **penambahan fitur fisis pendukung** seperti jarak, kedalaman dan lain lain.



Daftar Pustaka



- Torrence, C., Compo, G.P., 1998. A practical guide to wavelet analysis. *Bull. Am. Meteorol. Soc.* 79, 61–78.
[https://doi.org/10.1175/1520-0477\(1998\)079<0061:APGTWA>2.0.CO;2](https://doi.org/10.1175/1520-0477(1998)079<0061:APGTWA>2.0.CO;2)
- BMKG, 2022. Laporan Kinerja 2022 Badan Meteorologi, Klimatologi, dan Geofisika. Jakarta.
- Tempo, 2023. BMKG Riset Aplikasi Peringatan Dini Gempa.
- Mousavi, S.M., Ellsworth, W.L., Zhu, W., Chuang, L.Y., Beroza, G.C., 2020. Earthquake transformer—an attentive deep learning model for simultaneous earthquake detection and phase picking. *Nat. Commun.* 11.
<https://doi.org/10.1038/s41467-020-17591-w>
- Marzuki, M., Hamidi, M., Ahadi, S., Putra, A., Afdal, A., Harmadi, H., Karmawati, D., Suprihatih, H.S., Syirojudin, M., Maryam, I., 2022. ULF geomagnetic anomaly associated with the Sumatra-Pagai Islands earthquake swarm during 2020. *Contributions to Geophysics and Geodesy* 52, 185–207.
<https://doi.org/10.31577/congeo.2022.52.2.2>
- The PyWavelets Developers, 2026. Continuous Wavelet Transform (CWT).
- He, K., Zhang, X., Ren, S., Sun, J., 2016. Deep Residual Learning for Image Recognition, in: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. pp. 770–778.
<https://doi.org/10.1109/CVPR.2016.90>
- Molchanov, O.A., Hayakawa, M., 1998. On the generation mechanism of ULF seismogenic electromagnetic emissions. *Physics of the Earth and Planetary Interiors* 105, 201–210.
[https://doi.org/10.1016/S0031-9201\(97\)00087-0](https://doi.org/10.1016/S0031-9201(97)00087-0)
- Uyeda, S., Nagao, T., Kamogawa, M., 2009. Short-term earthquake prediction: Current status of seismo-electromagnetics. *Tectonophysics* 470, 205–213.
<https://doi.org/10.1016/j.tecto.2008.07.017>






TERIMA KASIH


Scalogram

1) Sinyal geomagnetik mentah (nT)



↓ CWT

2) Scalogram waktu-frekuensi



Pola anomali lokal lebih mudah terlihat pada domain waktu-frekuensi.

1) Mengapa menggunakan CWT Scalogram?

- Sinyal geomagnetik bersifat non-stasioner, sehingga amplitudo dan frekuensi dapat berubah terhadap waktu.
- Representasi sinyal mentah dalam nanoTesla hanya menunjukkan perubahan amplitudo terhadap waktu.
- Dalam analisis prekursor, yang penting bukan hanya seberapa besar sinyal, tetapi juga kapan dan pada frekuensi mana energi muncul.
- CWT mengubah sinyal menjadi representasi waktu-frekuensi, sehingga pola lokal lebih mudah dipelajari model.

2) Persamaan dasar CWT

$$W_n(s) = \sum_{n'=0}^{N-1} x_{n'} \psi^* \left(\frac{(n' - n)\Delta t}{s} \right)$$

$W_n(s)$: koefisien wavelet pada waktu n dan skala s

$x_{n'}$: nilai sinyal pada indeks waktu n'

ψ^* : kompleks konjugat mother wavelet

Δt : interval sampling

s : skala wavelet

3) Pembentukan scalogram

$$P[i, n] = |\text{coefficients}[i, n]|^2$$

Intensitas warna pada scalogram merepresentasikan energi lokal sinyal pada waktu dan frekuensi tertentu.



Inti alasan: scalogram CWT dipilih karena memberikan representasi waktu-frekuensi yang lebih informatif dan lebih mudah dipelajari model dibandingkan sinyal geomagnetik mentah dalam nanoTesla.



Fourier konvensional menunjukkan kandungan frekuensi secara umum, tetapi tidak langsung menunjukkan kapan komponen frekuensi tersebut muncul.

HASIL PREDIKSI PRECURSOR

data training

Metrik	Nilai
Accuracy	0,9754
Precision	1,00
Recall	0,968
F1-Score	0.9838

Confusion Matrix — Train

Aktual	Prediksi	
	Negatif	Positif
Negatif	623	0
Positif	67	2030

PENELITIAN ARFAN MENGGUNAKAN EfficientNetB0

data test

Metrik	Nilai
Accuracy	0,9717
Precision	1,00
Recall	0,9633
F1-Score	0.9813

Confusion Matrix — Test

Aktual	Prediksi	
	Negatif	Positif
Negatif	268	0
Positif	33	867

HASIL KLASIFIKASI MAGNITUDO

data Validation

Learning Rate	0.0023127077942294337
Weight Decay	2.683123007886481e-06
Dropout Rate	0.10990749972525041
Embedding Dimension	122

Confusion Matrix — Validation

Aktual	Prediksi	
	Negatif	Positif
Negatif	178	22
Positif	86	1258


**PENELITIAN ARFAN MENGGUNAKAN
EfficientNetB0**

HASIL PREDIKSI MAGNITUDO

data training

Metrik	Nilai
Accuracy	0,5769
Precision	0.6894
Recall	0,5794
F1-Score	0.5652

Confusion Matrix — Train




PENELITIAN ARFAN MENGGUNAKAN EfficientNetB0

data test

Metrik	Nilai
Accuracy	0,5633
Precision	0,5753
Recall	0,5632
F1-Score	0.5499


Confusion Matrix — Test



HASIL PREDIKSI MAGNITUDO

data validation

Metrik	Nilai
Accuracy	0,4211
Precision	0,4152
Recall	0,3736
F1-Score	0.3111



**PENELITIAN ARFAN
MENGGUNAKAN
EfficientNetB0**





Figure 6. The comparison results of the predicted and true values of LSTM in the test set.

Time Window	MAE	MSE	RMSE	Accuracy Rate	Accuracy Rate of $5 < M_L \leq 6$	Accuracy Rate of $M_L > 6$
2Y	0.57	0.41	0.64	39%	54%	5%
5Y	0.55	0.44	0.66	54%	68%	26%
10Y	0.48	0.30	0.55	68%	85%	37%

Jumlah Kelas Data Test 2025

