

PERANCANGAN SISTEM DETEKSI DINI GEMPA BUMI BERBASIS RESIDUAL NEURAL NETWORK UNTUK ESTIMASI MAGNITUDO GEMPA

Jordan Arya Leksana, Dr. Bambang Lelono Widjiantoro, S.T., M.T.

Teknik Fisika, Fakultas Teknologi Industri dan Rekayasa Sistem, Institut Teknologi Sepuluh

Nopember (ITS)

Jl. Arief Rahman Hakim, Surabaya 60111

e-mail: jordanaryaleksana41@email.com

Abstrak—Indonesia merupakan wilayah dengan aktivitas seismik tinggi sehingga pengembangan sistem deteksi dini gempa bumi menjadi aspek penting dalam upaya mitigasi bencana. Penelitian ini mengembangkan sistem deteksi prekursor gempa bumi serta estimasi kelas magnitudo berdasarkan analisis sinyal geomagnetik Ultra Low Frequency (ULF) pada pita Pc3. Pendekatan berbasis deep learning diterapkan menggunakan arsitektur Residual Neural Network (ResNet-18) dengan skema multi-task learning multi-stasiun. Data geomagnetik komponen H, D, dan Z dari jaringan stasiun BMKG tahun 2018–2025 diseleksi berdasarkan kedekatan stasiun terhadap episentrum dan kondisi geomagnetik tenang. Selanjutnya, sinyal diproses melalui penyaringan pita Pc3 dan ditransformasikan menggunakan Continuous Wavelet Transform (CWT) menjadi representasi scalogram. Model yang dikembangkan memiliki dua head keluaran, yaitu head deteksi prekursor dan head klasifikasi magnitudo. Hasil pengujian menunjukkan bahwa model mampu mendeteksi prekursor gempa dengan akurasi sebesar 88,38% serta nilai precision dan recall yang seimbang pada kedua kelas. Selain itu, interpretasi model menggunakan Gradient-weighted Class Activation Mapping (Grad-CAM) menunjukkan adanya pola aktivasi yang stabil dan konsisten antar-stasiun pada tugas deteksi prekursor. Sementara itu, estimasi magnitudo tiga kelas masih menunjukkan keterbatasan performa dengan akurasi sebesar 52,67%, yang dipengaruhi oleh ketidakseimbangan distribusi kelas serta lemahnya keterkaitan langsung antara amplitudo anomali geomagnetik dan magnitudo gempa. Penelitian ini menunjukkan bahwa pemanfaatan deep learning pada analisis sinyal geomagnetik memiliki potensi untuk mendukung pengembangan teknologi mitigasi bencana. Selain itu, pendekatan yang dikembangkan sejalan dengan SDGs poin 9 melalui penerapan inovasi berbasis kecerdasan buatan, serta SDGs poin 13 dalam upaya meningkatkan ketangguhan masyarakat terhadap risiko bencana.

Kata Kunci—Continuous Wavelet Transform, Deteksi Dini Gempa, Multi-task Learning, Prekursor ULF, Residual Neural Network, Sinyal Geomagnetik.

I. PENDAHULUAN

Indonesia merupakan negara kepulauan yang secara geotektonik terletak pada pertemuan tiga lempeng aktif dunia, yaitu Lempeng Indo-Australia, Eurasia, dan Pasifik. Konfigurasi tektonik tersebut menjadikan Indonesia salah satu wilayah dengan tingkat aktivitas seismik tertinggi di dunia, dengan frekuensi gempa tektonik yang tinggi dan pada sejumlah kasus diikuti bencana ikutan berupa tsunami di wilayah pesisir yang berdekatan dengan zona subduksi. Laporan resmi Badan Meteorologi, Klimatologi, dan Geofisika menunjukkan bahwa gempa-gempa signifikan di berbagai wilayah Indonesia telah menimbulkan korban jiwa, kerusakan infrastruktur, serta gangguan sosial-ekonomi yang berdampak langsung terhadap perekonomian nasional [1].

Kondisi ini menegaskan bahwa sistem mitigasi bencana, khususnya sistem peringatan dini gempa, memiliki peran strategis dalam menekan tingkat risiko dan kerugian..

Meskipun demikian, keterbatasan waktu peringatan dan kompleksitas proses deteksi menyebabkan sistem peringatan dini masih menghadapi berbagai tantangan [2]. Sistem yang ideal tidak hanya dituntut mampu mendeteksi kejadian gempa secara cepat, tetapi juga mengekstraksi parameter penting gempa, seperti magnitudo, secara akurat dan langsung dari sinyal observasi [3]. Oleh karena itu, dibutuhkan pendekatan deteksi dini yang lebih andal, adaptif, dan informatif untuk mendukung penguatan sistem peringatan dini yang telah ada.

Salah satu indikator fisis yang menjanjikan pada fase persiapan gempa adalah anomali gelombang elektromagnetik *Ultra Low Frequency* (ULF). Emisi ULF diyakini berkaitan dengan perubahan sifat fisik batuan akibat akumulasi tegangan di zona seismogenik, seperti pembentukan retakan mikro dan perubahan distribusi muatan listrik yang menimbulkan arus listrik lokal melalui mekanisme elektrokinetik dan piezomagnetik [4]. Karena memiliki frekuensi rendah dengan redaman yang relatif kecil, sinyal ULF dari zona patahan mampu merambat hingga ke permukaan dan terdeteksi oleh magnetometer, sehingga anomali ULF kerap dikaji sebagai prekursor elektromagnetik sebelum pelepasan energi seismik utama [5].


Dalam praktiknya, analisis sinyal ULF umumnya dilakukan menggunakan pendekatan konvensional berbasis pengolahan sinyal geomagnetik, seperti penyaringan frekuensi tertentu, analisis spektrum daya, serta evaluasi rasio polarisasi antara komponen vertikal dan horizontal medan geomagnetik (Z/H) [6]. Namun, pendekatan berbasis parameter tunggal memiliki keterbatasan dalam membedakan variasi yang berasal dari proses seismogenik dengan gangguan eksternal, khususnya aktivitas geomagnetik global yang dapat menghasilkan karakteristik sinyal serupa [5]. Sebagai respons terhadap keterbatasan tersebut, metode berbasis *deep learning* menawarkan potensi signifikan dalam pengolahan data geofisika yang kompleks dan berdimensi tinggi [7], karena mampu mempelajari pola pembeda secara langsung dari data tanpa bergantung pada satu parameter saja. Salah satu arsitektur yang banyak digunakan dalam ekstraksi fitur kompleks adalah *Residual Neural Network* (ResNet), yang memanfaatkan konsep *residual learning* melalui *shortcut connection* untuk mengatasi degradasi performa pada jaringan dalam [8]. Struktur residual memungkinkan model mempelajari representasi fitur yang lebih stabil dan mempertahankan informasi penting dari sinyal input, sehingga meningkatkan kemampuan generalisasi pada data

dengan tingkat kebisingan tinggi [8]. Pada penelitian ini, pendekatan berbasis ResNet dikembangkan dengan skema *multi-task learning* dan arsitektur multi-stasiun yang dipadukan mekanisme atensi antar-stasiun, sehingga model dapat mengekstraksi pola spasial-temporal dari representasi waktu-frekuensi sinyal geomagnetik sekaligus mengestimasi parameter gempa secara simultan.

Berdasarkan uraian tersebut, penelitian ini bertujuan untuk: (1) mengembangkan model *deep learning* berbasis ResNet dengan pendekatan *multi-task learning* multi-stasiun untuk mengenali pola prekursor gempa sekaligus mengestimasi magnitudo dari representasi *scalogram* sinyal ULF; serta (2) menerapkan dan mengevaluasi kinerja model dalam menangkap pola prekursor dan mengestimasi magnitudo pada data yang mengandung variasi tingkat kebisingan dan gangguan eksternal, ditinjau dari akurasi, konsistensi, dan ketahanan model.

II. METODOLOGI

A. Diagram Alir Penelitian




Gambar. 1 Diagram Alir Penelitian

Diagram alir pada Gambar 1 disusun untuk memudahkan pemahaman terhadap alur kerja sekaligus memastikan setiap tahapan teridentifikasi secara terstruktur. Penelitian ini dilaksanakan di Departemen Teknik Fisika, Institut Teknologi Sepuluh Nopember (ITS). Adapun alur penelitian secara keseluruhan, mulai dari tahap perancangan, pengembangan model, hingga evaluasi performa, disusun secara sistematis sebagaimana ditunjukkan pada Gambar Tahap Penyuntingan dan Publikasi

B. Akuisisi Data

Data utama yang digunakan berupa data geomagnetik dari jaringan stasiun pengamatan Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) pada rentang tahun 2018–2025, yang tersebar di berbagai wilayah Indonesia mulai dari Sumatra, Jawa, Kalimantan, Sulawesi, hingga Papua sebagaimana ditunjukkan pada Gambar 2. Data direkam pada resolusi temporal 1 Hz dan mencakup tiga komponen medan magnet, yaitu horizontal (H), deklinasi (D), dan vertikal (Z), yang lazim digunakan dalam analisis



Gambar. 2 Peta lokasi stasiun pengamatan geomagnetik BMKG yang digunakan dalam penelitian

fenomena elektromagnetik terkait aktivitas seismik [9]. Selain sinyal geomagnetik, digunakan pula katalog gempa bumi yang memuat waktu kejadian, lokasi episentrum, dan magnitudo. Katalog ini berfungsi menentukan periode pra-kejadian (*pre-seismic period*), yaitu rentang waktu sebelum gempa yang diasumsikan berpotensi mengandung sinyal prekursor, sehingga data pada beberapa hari sebelum kejadian dipilih sebagai kandidat analisis. Kemudian ditentukan data 2018–2024 menjadi data *train* dan validasi kemudian untuk data 2025 digunakan sebagai data *test*.

C. Seleksi Event, Stasiun, dan Kondisi Geomagnetik

Pemilihan stasiun tidak dilakukan dengan mengambil seluruh stasiun pada radius tertentu, melainkan melalui pendekatan berbasis kejadian (*event-based selection*). Untuk

Tabel 1.
Nilai *constant ratio* untuk berbagai kombinasi pasangan

No	Kategori Badai	Rentang DST (nT)
1	Weak	$-30 \geq \text{Dst} > -50$
2	Moderate	$-50 \geq \text{Dst} > -100$
3	Strong	$-100 \geq \text{Dst} > -200$
4	Very Strong	$-200 \geq \text{Dst} > -300$
5	Super	$\text{Dst} \leq -300$

setiap gempa, dihitung jarak antara episentrum dan setiap stasiun menggunakan metode *haversine*:

$$d = 2R \arcsin \left(\sqrt{\sin^2 \left(\frac{\Delta\phi}{2} \right) + \cos \phi_1 \cos \phi_2 \sin^2 \left(\frac{\Delta\lambda}{2} \right)} \right) \quad (1)$$

dengan d jarak episentrum–stasiun, R jari-jari bumi (≈ 6371 km), ϕ_1 dan ϕ_2 lintang kedua titik, serta $\Delta\phi$ dan $\Delta\lambda$ selisih lintang dan bujunya. Kejadian gempa dipertahankan apabila memiliki setidaknya satu stasiun dengan jarak kurang dari

500 km, kemudian dipilih K stasiun terdekat (*top-K nearest stations*) dengan $K = 3$ untuk tiap kejadian.

Untuk menekan gangguan eksternal akibat aktivitas geomagnetik global, diterapkan seleksi berbasis indeks *Disturbance Storm Time* (DST) sebagaimana klasifikasi pada Tabel 1; data hanya digunakan pada kondisi geomagnetik tenang, yaitu $DST > -30$ nT, agar sinyal yang dianalisis lebih merepresentasikan proses internal bumi yang berkaitan dengan aktivitas seismik [9].


D. Pengambilan Data dari Sensor Geomagnetik

Data geomagnetik pada penelitian ini diperoleh dari sensor magnetometer yang dikelola oleh BMKG. Pengambilan data dilakukan dengan mengakses server yang telah diberikan izin menggunakan *Secure Shell* (SSH) dan untuk membaca dan mengirim file digunakan *Secure File Transfer Protocol* (SFTP). Data diperoleh dalam bentuk binary dengan ukuran per parameter 4 byte. Lengkapnya dapat dilihat melalui Tabel 2 dibawah ini.

Tabel 2.
Format Data Sensor Magnetometer

No	Field	Tipe Data	Ukuran
1	Hcomp	Float32	4 byte
2	Dcomp	Float32	4 byte
3	Zcomp	Float32	4 byte
4	Tcomp	Float32	4 byte
5	Komponen tambahan sensor	Float32	4 byte
6	Temperatur sensor	Float32	4 byte
7	Temperatur perangkat	Float32	4 byte
8	Voltage	Float32	4 byte

Dalam penelitian ini hanya mengambil 3 komponen geomagnetik utama yaitu Hcomp, Dcomp, dan Zcomp. Ketiga komponen tersebut dipilih karena merepresentasikan variasi nilai medan geomagnetic yang dibutuhkan dalam proses analisis sinyal.




Gambar. 3 Diagram Blok Pengambilan Data Sensor Geomagnetik.

Pada Gambar 3 ditampilkan alur pengambilan dan pengolahan awal data sensor geomagnetik. Proses dimulai dari akses ke server BMKG melalui SFTP (Secure File Transfer Protocol) untuk mengunduh data sensor secara aman. Data yang diperoleh masih dalam bentuk file biner, sehingga diperlukan proses pembacaan berdasarkan format record sensor yang digunakan. Selanjutnya, nilai mentah hasil pembacaan dikonversi dengan menggunakan baseline stasiun dan faktor skala. Tahap ini penting karena setiap stasiun memiliki karakteristik lokasi, kondisi instrumen, serta nilai

medan geomagnetik dasar yang berbeda. Oleh karena itu, koreksi baseline dilakukan untuk mengurangi pengaruh offset pada data sensor agar nilai komponen geomagnetik yang dihasilkan lebih merepresentasikan kondisi sebenarnya di masing-masing stasiun. Setelah proses konversi dilakukan, data disusun ke dalam format terstruktur dengan fokus pada komponen H, D, dan Z. Komponen H dan Z umumnya dinyatakan dalam satuan nanoTesla (nT), sedangkan komponen D merepresentasikan deklinasi atau sudut sesuai dengan format data stasiun. Data yang telah tersusun secara terstruktur kemudian digunakan sebagai masukan pada tahap preprocessing.

E. Pra-pemrosesan Sinyal ULF

Tahap pra-pemrosesan ditujukan untuk meningkatkan kualitas sinyal prekursor yang beramplitudo rendah, non-stasioner, dan sering tertutup *noise* [10]. Data mentah komponen H, D, dan Z terlebih dahulu dikonversi ke sistem ortogonal X, Y, Z mengikuti kaidah elemen geomagnetik agar setiap komponen saling tegak lurus.




Gambar. 4 Hasil Pemfilteran Pc3 dan pengubahan Sinyal HDZ diubah ke Arah XYZ

Penyaringan dilakukan menggunakan *band-pass filter* Butterworth orde keempat pada pita Pc3 (0,022–0,1 Hz) yang sensitif terhadap fenomena prekursor [9], diterapkan secara dua arah (*forward-backward*) sehingga menghasilkan penyaringan tanpa pergeseran fasa (*zero-phase*), sementara nilai hilang ditangani melalui interpolasi linear. Pengaruh penyaringan ditunjukkan pada Gambar 4, di mana tren dan komponen di luar pita Pc3 teredam dan menyisakan variasi ULF yang menjadi fokus analisis.


Selanjutnya sinyal disegmentasi per jam, dan dari tiap segmen dihitung rasio variansi antara komponen vertikal dan horizontal (Z/H). Rasio Z/H berperan ganda: sebagai kriteria seleksi sekaligus dasar pelabelan awal, di mana segmen dengan rasio menonjol diyakini memuat prekursor dan

ditandai sebagai kelas prekursor, sedangkan rasio rendah ditandai non-prekursor (Gambar 5). Akhirnya dilakukan *downsampling* berbasis perata-rataan jendela untuk mengurangi dimensi dan *noise* tanpa menghilangkan karakteristik utama sinyal.



Gambar. 5 Penyaringan sinyal Anomali menggunakan Rasion Z/H dan windowing signal 1 jam

F. Transformasi Waktu-Frekuensi



Gambar. 6 Hasil Transformasi dari Wavelet menuju Scalogram

Sinyal hasil pra-pemrosesan ditransformasikan dari domain waktu ke domain waktu-frekuensi menggunakan

Continuous Wavelet Transform (CWT) untuk menghasilkan *scalogram* yang menggambarkan distribusi energi sinyal terhadap waktu dan frekuensi secara simultan. CWT dipilih karena memiliki resolusi waktu-frekuensi adaptif yang sesuai untuk sinyal non-stasioner seperti ULF, dibandingkan transformasi Fourier konvensional [11]. Wavelet induk yang digunakan adalah *Complex Morlet* *cmor1.5-1.0*, dengan lebar pita 1,5 dan frekuensi pusat 1,0, yang bersifat kompleks sehingga mampu menangkap amplitudo sekaligus fase, serta memiliki *envelope* Gaussian yang menyeimbangkan resolusi waktu dan frekuensi

Hasil transformasi untuk ketiga komponen geomagnetik ditunjukkan pada Gambar 6. Pada tahap awal, sinyal komponen X, Y, dan Z diubah ke dalam bentuk scalogram menggunakan transformasi CWT sehingga pola sinyal tidak hanya diamati berdasarkan perubahan amplitudo terhadap waktu, tetapi juga berdasarkan distribusi energi pada berbagai skala. Setelah proses transformasi dilakukan, ketiga hasil scalogram tersebut kemudian digabungkan menjadi tensor scalogram tiga kanal yang digunakan sebagai masukan model. Dengan demikian, setiap sampel data tidak hanya merepresentasikan satu komponen sinyal, tetapi memuat informasi gabungan dari tiga komponen geomagnetik secara simultan.

Pada Gambar 6 juga diperlihatkan perbandingan antara hasil scalogram sebelum dan sesudah proses loader, termasuk penerapan transformasi log dan global score. Hasil setelah loader menunjukkan pola distribusi energi yang lebih terstandarisasi sehingga perbedaan intensitas antarbagian scalogram menjadi lebih mudah diamati. Pada sampel normal atau non-prekursor, energi cenderung tersebar dan tidak membentuk konsentrasi yang sangat dominan pada satu rentang waktu tertentu. Sebaliknya, pada sampel prekursor, pola energi biasanya lebih kuat, terlokalisasi, dan muncul pada waktu atau skala tertentu, terutama pada komponen Z. Konsentrasi energi tersebut dapat menjadi informasi penting yang dipelajari oleh model untuk membedakan kondisi normal dan kondisi yang berpotensi berkaitan dengan aktivitas prekursor gempa. Namun, interpretasi visual ini tetap digunakan sebagai pendukung analisis, sedangkan keputusan akhir klasifikasi dilakukan oleh model berdasarkan representasi tensor scalogram tiga kanal yang diberikan sebagai input..


G. Perancangan Model

Arsitektur model yang dirancang ditunjukkan pada Gambar 7.

Secara umum, model merupakan jaringan *multi-task* multi-stasiun berbasis ResNet yang memproses sekumpulan stasiun terdekat untuk satu kejadian gempa, lalu menggabungkan informasinya menjadi satu representasi tingkat kejadian sebelum menghasilkan dua keluaran sekaligus.

Masukan model berupa citra *scalogram* multi-stasiun dengan dimensi [B, S, 3, H, W], dengan B ukuran *batch*, S jumlah stasiun terdekat (*top-K*), serta tiga kanal *scalogram* berukuran H×W piksel. Setiap stasiun terlebih dahulu diekstraksi fitur oleh *ResNet backbone* dengan bobot yang dibagikan (*shared*), mencakup lapisan conv1 hingga layer4 dan diakhiri *adaptive average pooling*, sehingga menghasilkan satu vektor fitur berdimensi F per stasiun [B, S, F]. Secara paralel, identitas tiap stasiun (ID Stasiun) dipetakan menjadi vektor melalui lapisan *Station Embedding*

berdimensi 64 yang nilainya ikut dipelajari selama pelatihan. Vektor fitur *backbone* dan *station embedding* kemudian digabungkan (*concatenation*) menjadi representasi [B, S, F+64], sehingga model tidak hanya mengenali pola sinyal tetapi juga mengaitkannya dengan karakteristik khas tiap stasiun.



Gambar. 7 Perancangan Arsitektur Model

Representasi gabungan diproses oleh blok *Proyeksi Fitur* (Linear + LayerNorm + ReLU + Dropout) yang menyeragamkan dimensi menjadi 512 [B, S, 512]. Selanjutnya, *Transformer Encoder* dengan mekanisme atensi antar-stasiun (*multi-head self-attention* empat *head*) memodelkan keterkaitan antar-stasiun, dilengkapi *masking* untuk mengabaikan stasiun *padding*. Keluaran encoder kemudian diringkas oleh *Masked Attention Pooling*, yang mengagregasi seluruh S stasiun menjadi satu vektor *event* berdimensi 512 dengan membobot kontribusi tiap stasiun secara adaptif.

Vektor *event* dialirkan ke lapisan *Shared Fully Connected* (Linear + LayerNorm + ReLU + Dropout) sebagai representasi bersama, lalu bercabang ke dua *head* sesuai skema *multi-task learning*. *Precursor Head* melakukan klasifikasi biner untuk menentukan keberadaan prekursor (prekursor/non-prekursor), sedangkan *Magnitude Head* melakukan klasifikasi magnitudo ke dalam tiga kelas. Dengan struktur ini, kedua tugas berbagi representasi fitur yang sama namun memiliki jalur keputusan masing-masing, sehingga model dapat mendeteksi prekursor dan mengestimasi magnitudo secara simultan dalam satu kali proses *inference*.

H. Pelatihan dan Evaluasi Model

Dataset dibagi menjadi data latih dan validasi dengan rasio 8:2, lalu dimuat melalui *dataloader* yang mengintegrasikan citra *scalogram*, koordinat stasiun, dan katalog gempa. Konfigurasi pelatihan yang digunakan adalah, 150 *epoch*, ukuran *batch* 16, *learning rate* 1×10^{-5} , dan *weight decay* 1×10^{-5} sebagai regularisasi. Untuk menjaga kestabilan konvergensi, *learning rate* disesuaikan secara dinamis

menggunakan penjadwal *ReduceLROnPlateau* yang menurunkan laju ketika *loss* validasi tidak membaik selama sejumlah *epoch* tertentu. Seluruh pelatihan dijalankan pada GPU NVIDIA GeForce RTX 5070 (12 GB VRAM) di lingkungan Ubuntu 24.04. Kinerja model dievaluasi menggunakan *accuracy*, *precision*, *recall*, dan *F1-score* dengan pendekatan *macro averaging* agar setiap kelas memperoleh bobot setara, sementara distribusi prediksi diperiksa melalui *confusion matrix*. Untuk memahami dasar pengambilan keputusan model, diterapkan pula analisis *Gradient-weighted Class Activation Mapping* (Grad-CAM) pada data validasi guna menampilkan wilayah *scalogram* yang paling berpengaruh terhadap keluaran tiap *head*. penutupnya. Diberlakukan juga Test pada model yang telah lolos pelatihan dengan data gempa bumi tahun 2025.

III. HASIL DAN PEMBAHASAN

A. Hasil Akuisisi Data

Hasil dari pengambilan dataset didapatkan sejumlah dataset yang ditampilkan pada Tabel 3, 4 dan 5 dibawah yang memberikan ringkasan kuantitatif mengenai jumlah sampel yang berhasil dikumpulkan dari jenis *train*, *validation* dan *data test*.

Tabel 3.
Hasil Akuisisi Data Train

No	Kategori Data	Jumlah Sampel
1	Normal	1901
2	Moderate	2400
3	Medium	2080
5	Large	748

Tabel 4.
Hasil Akuisisi Data Validation

No	Kategori Data	Jumlah Sampel
1	Normal	186
2	Moderate	520
3	Medium	599
5	Large	475

Tabel 5.
Hasil Akuisisi Data Test

No	Kategori Data	Jumlah Sampel
1	Normal	513
2	Moderate	484
3	Medium	123
5	Large	79


Pengelompokan kelas dilakukan berdasarkan kondisi non-prekursor dan rentang magnitudo gempa. Kelas “Normal” merepresentasikan kondisi non-prekursor, kelas “Moderate” merepresentasikan kejadian dengan magnitudo 4–5, kelas “Medium” merepresentasikan kejadian dengan magnitudo 5–6, sedangkan kelas “Large” merepresentasikan kejadian dengan magnitudo ≥ 6 .

B. Hasil Training Model

Berikut merupakan rekapitulasi proses pelatihan untuk kedua *head* keluaran model ditunjukkan pada Gambar 7 dan


Gambar 8, yang masing-masing menampilkan kurva akurasi *head* prekursor serta kurva *macro-F1 head* magnitudo sepanjang proses pelatihan.

1) Hasil Training Head Prekursor



Gambar. 7 Kurva Hasil Akurasi Training Prekursor

Kurva pada Gambar 7 memperlihatkan bahwa *head* prekursor mencapai konvergensi yang cepat dan stabil. Akurasi pelatihan meningkat tajam dari sekitar 0,77 pada *epoch* awal menjadi di atas 0,90 hanya dalam beberapa *epoch* pertama, kemudian bergerak stabil pada kisaran 0,93–0,94 hingga akhir pelatihan. Akurasi validasi mengikuti pola serupa dan stabil pada kisaran 0,90–0,92, dengan selisih yang relatif kecil dan konsisten terhadap akurasi pelatihan. Kedekatan kedua kurva ini menunjukkan bahwa model tidak mengalami *overfitting* yang berarti memiliki kemampuan generalisasi yang baik dalam membedakan segmen prekursor dari non-prekursor. Hal ini mengindikasikan bahwa representasi *scalogram* dari sinyal ULF memuat pola pembeda yang cukup kuat dan konsisten untuk dipelajari model pada tugas deteksi prekursor. Hasil Training Head Magnitudo



Gambar. 8 Kurva Hasil Akurasi Training Magnitudo

Berbeda dengan *head* prekursor, kurva akurasi pada Gambar 8 menunjukkan proses pembelajaran yang jauh lebih lambat dan menantang. Akurasi pelatihan bermula dari kisaran rendah, yaitu sekitar 0,39, kemudian meningkat secara bertahap namun konsisten seiring bertambahnya *epoch* hingga mencapai sekitar 0,63 pada akhir pelatihan. Sementara itu, akurasi validasi sempat melonjak ke sekitar 0,55 pada *epoch* awal, lalu bergerak fluktuatif pada kisaran 0,48–0,53 dan cenderung mendatar (*plateau*) hingga akhir pelatihan. Pola ini memperlihatkan dua karakteristik penting.

Pertama, nilai akurasi yang rendah secara keseluruhan menandakan bahwa tugas estimasi magnitudo jauh lebih sulit dipelajari dibanding deteksi prekursor. Kedua, akurasi pelatihan yang terus menanjak sementara akurasi validasi tertahan menyebabkan jarak keduanya melebar pada *epoch* lanjut, yang mengindikasikan kecenderungan *overfitting*, yaitu model mulai menghafal data latih tanpa diiringi peningkatan generalisasi yang sepadan pada data validasi.

C. Hasil Uji pada data 2025


1) Hasil uji prekursor

Tabel 6.
Metrik Hasil Uji Prekursor

No	Metrik	Nilai
1	Accuracy	0,8825
5	Macro F1	0,8838

Kinerja *head* prekursor pada tahap pengujian dirangkum pada Tabel 6. Model mencapai akurasi sebesar 0,8838 dan *macro F1* 0,8838. Kedekatan nilai kedua metrik tersebut menunjukkan bahwa kinerja model seimbang dan tidak berat sebelah ke salah satu kelas.

Distribusi prediksi model divisualisasikan melalui *confusion matrix* pada Gambar 9. Dari kelas non-prekursor, sebanyak 381 sampel (87,6%) diklasifikasikan dengan benar, sedangkan 54 sampel (12,4%) keliru diprediksi sebagai prekursor. Pada kelas prekursor, model berhasil mengenali 400 sampel (88,9%) secara benar, dengan hanya 50 sampel (11,1%) yang terlewat dan terklasifikasi sebagai non-prekursor.



Gambar. 9 Hasil Confusion Matrix dari *Head* Prekursor

Mayoritas prediksi yang terkonsentrasi pada diagonal utama menegaskan kemampuan generalisasi model yang baik dalam membedakan keberadaan prekursor. Pola kesalahan ini memiliki implikasi yang menguntungkan dalam konteks sistem peringatan dini. *Recall* yang tinggi pada kedua kelas, 88,9% untuk prekursor dan 87,6% untuk non-prekursor menunjukkan bahwa model jarang gagal mengenali kondisi yang sebenarnya terjadi, baik saat prekursor benar-benar ada maupun saat tidak ada. *Recall* prekursor yang tinggi berarti jumlah *false negative* dapat ditekan, yaitu sedikitnya prekursor nyata yang terlewat;

sementara *recall* non-prekursor yang tinggi berarti *false positive* juga terkendali, yaitu jarang terjadi kondisi normal yang


keliru dianggap sebagai prekursor. Keseimbangan ini penting karena kedua jenis kesalahan memiliki konsekuensi yang berbeda namun sama-sama merugikan: kegagalan mendeteksi prekursor (*false negative*) berisiko menghilangkan kesempatan mitigasi sebelum gempa terjadi, sedangkan peringatan palsu yang terlalu sering (*false positive*) dapat menurunkan kepercayaan publik terhadap sistem dan memicu kelelahan peringatan (*alarm fatigue*).

2) Hasil uji Magnitudo

Tabel 6.
Metrik Hasil Uji Magnitudo

No	Metrik	Nilai
1	Accuracy	0,5267
2	Macro F1	0,3253

Berbeda dengan *head* prekursor, kinerja *head* magnitudo pada tahap pengujian jauh lebih terbatas sebagaimana dirangkum pada Tabel 6. Model hanya mencapai akurasi sebesar 0,5267 dengan *macro F1* sebesar 0,3253. Selisih yang lebar antara akurasi dan *macro F1* tersebut merupakan indikasi kuat adanya ketidakseimbangan kinerja antar-kelas: nilai akurasi yang relatif lebih tinggi cenderung didominasi oleh kelas mayoritas, sedangkan *macro F1* yang rendah mengungkap lemahnya kemampuan model pada kelas-kelas minoritas yang memperoleh bobot setara dalam perhitungan *macro averaging*.



Gambar. 10 Hasil Confusion Matrix dari *Head* Magnitudo

Pola ketidakseimbangan tersebut terlihat jelas pada *confusion matrix* di Gambar 10. Kelas *Moderate* terklasifikasi paling baik dengan *recall* 66%, namun sisanya tersebar sebagai kesalahan ke kelas *Large* (15%) dan *Medium* (18%). Kelas *Medium* menunjukkan kinerja terburuk dengan *recall* hanya 20%, bahkan lebih banyak sampelnya (68%) keliru diprediksi sebagai *Moderate*. Demikian pula kelas *Large* yang hanya memperoleh *recall* 12%, dengan 84% sampelnya salah diklasifikasikan sebagai *Moderate*. Terlihat bahwa kesalahan klasifikasi secara konsisten condong menuju kelas *Moderate*, yang mengindikasikan bahwa model cenderung memprediksi kelas mayoritas ketika dihadapkan pada sinyal yang ambigu.


Kecenderungan ini berakar pada dua faktor utama. Pertama, ketidakseimbangan distribusi data antar-kelas magnitudo menyebabkan model lebih banyak terpapar pola kelas *Moderate* selama pelatihan, sehingga bias prediksinya mengarah ke kelas tersebut. Kedua, dan lebih mendasar, informasi pembeda magnitudo pada sinyal ULF tampaknya tidak cukup kuat dan konsisten untuk memisahkan ketiga tingkat magnitudo. Berbeda dengan deteksi prekursor yang hanya menuntut model mengenali ada atau tidaknya anomali, estimasi magnitudo menuntut model memetakan perbedaan amplitudo dan distribusi energi yang halus menjadi tingkatan magnitudo yang diskret, padahal hubungan antara amplitudo anomali geomagnetik dan magnitudo gempa bersifat tidak langsung serta dipengaruhi faktor lain seperti jarak episentrum dan kedalaman sumber. Akibatnya, meskipun model mampu menangkap keberadaan prekursor dengan andal, model belum mampu menerjemahkan informasi tersebut menjadi estimasi magnitudo yang akurat. Sebuah keterbatasan yang akan ditelusuri lebih lanjut melalui interpretasi Grad-CAM pada subbab berikutnya.


D. Hasil Evaluasi Grad-CAM

Meskipun metrik seperti akurasi dan *F1-score* mampu mengukur kinerja model, metrik tersebut tidak menjelaskan bagaimana model sampai pada keputusannya, sehingga model cenderung bekerja sebagai *black box*. Untuk itu digunakan *Gradient-weighted Class Activation Mapping* (Grad-CAM), yaitu metode interpretasi visual yang memanfaatkan gradien kelas keluaran terhadap peta fitur konvolusi terakhir untuk menghasilkan peta panas (*heatmap*) yang menyoroti wilayah *scalogram* paling berpengaruh terhadap prediksi. Dalam penelitian ini, Grad-CAM berfungsi sekaligus untuk memverifikasi bahwa keputusan model didasarkan pada karakteristik fisis sinyal yang relevan dan untuk mendiagnosis perbedaan kinerja antar-*head*. Dasar penilaiannya adalah kriteria konsistensi: apabila model benar-benar mempelajari fitur pembeda, maka wilayah aktivasi untuk kelas yang sama semestinya konsisten antar-kejadian dan berbeda secara tegas antar-kelas yang berlainan, sedangkan aktivasi yang berpindah-pindah tanpa pola menandakan model belum menemukan fitur pembeda yang andal, atas dasar inilah Grad-CAM dipandang valid untuk menilai kemampuan diskriminatif model pada masing-masing *head*.

1) Interpretasi Grad-CAM Head Prekursor

Analisis Grad-CAM juga diterapkan pada *precursor head* untuk memverifikasi wilayah *scalogram* yang menjadi dasar keputusan model dalam membedakan kondisi prekursor dari non-prekursor. Visualisasinya ditunjukkan pada Gambar 11, dengan panel (a) dan (b) mewakili kasus prekursor dan panel (c) mewakili kasus non-prekursor.





Gambar. 11 Hasil *overlay* Grad-CAM pada *head* prekursor untuk tiga kondisi pengamatan: (a) Stasiun LWA pada 25 Januari 2019 (kasus prekursor), (b) Stasiun SCN pada 25 Januari 2019 (kasus prekursor), dan (c) Stasiun SBG pada 27 Maret 2019 (kasus non-prekursor).

Pada kasus prekursor pertama (Stasiun LWA, 25 Januari 2019), aktivasi Grad-CAM bersifat sangat terlokalisasi dan konsisten. Wilayah aktivasi terkuat terkonsentrasi di tepi kanan *scalogram* pada rentang indeks waktu sekitar 460–510, terutama pada bagian frekuensi rendah (pojok kanan bawah), membentuk satu area panas yang padat dan terfokus di tengah latar yang aktivasinya rendah. Pola ini hampir identik pada ketiga komponen H, D, dan Z, yang menunjukkan bahwa model menyandarkan keputusan deteksi prekursornya pada satu wilayah yang stabil dan terdefinisi dengan jelas.



Pola yang serupa kembali muncul pada kasus prekursor kedua (Stasiun SCN, 25 Januari 2019). Meskipun pengamatan ini berasal dari stasiun yang berbeda, aktivasi Grad-CAM tetap terkonsentrasi pada wilayah tepi kanan *scalogram* di pita frekuensi rendah, dengan karakteristik area panas yang padat dan terlokalisasi seperti pada Stasiun LWA. Kesamaan tanda spasial pada dua stasiun yang berbeda ini merupakan validasi penting: hal tersebut menunjukkan bahwa wilayah yang disorot model bukanlah artefak khas satu stasiun atau satu kejadian, melainkan ciri prekursor yang konsisten dan dapat digeneralisasi. Dengan kata lain, model benar-benar mengenali pola fisis yang sama setiap kali kondisi prekursor muncul, bukan sekadar menghafal karakteristik satu lokasi.

Sebaliknya, pada kasus non-prekursor (Stasiun SBG, 27 Maret 2019), distribusi aktivasi terlihat jelas berbeda. Wilayah panas tidak lagi terpaku di tepi, melainkan tersebar pada bagian tengah *scalogram*, yaitu di sekitar indeks waktu 100–200 dan 380–420 pada pita frekuensi menengah, terbagi menjadi dua area terpisah dengan latar energi yang lebih menyebar. Perbedaan letak dan sebaran aktivasi ini menandakan bahwa model menanggapi kondisi non-prekursor dengan "pandangan" spasial yang berlainan dari kondisi prekursor.

Perbedaan yang tegas pada Gambar 11 antara tanda spasial prekursor yang konsisten terlokalisasi di tepi terbukti sama pada dua stasiun LWA dan SCN dengan aktivasi non-prekursor yang tersebar di bagian tengah merupakan indikasi kuat bahwa model telah mempelajari fitur pembeda yang stabil dan dapat diandalkan untuk kedua kelas. Konsistensi inilah yang menjelaskan tingginya akurasi deteksi prekursor (88,38%): karena pola prekursor muncul secara konsisten antar-stasiun dan mudah dipisahkan dari pola non-prekursor, tugas klasifikasi biner ini relatif mudah dipelajari model.

2) Interpretasi Grad-CAM Head Magnitudo

Untuk memahami dasar pengambilan keputusan model pada tugas estimasi magnitudo, diterapkan analisis Grad-CAM yang menyorot wilayah *scalogram* paling berpengaruh terhadap keluaran *magnitude head*. Visualisasi untuk tiga kejadian uji ditunjukkan pada Gambar 12, masing-masing menampilkan *overlay* Grad-CAM pada ketiga kanal komponen H, D, dan Z.



Gambar. 12 Hasil *overlay* Grad-CAM pada *head* magnitudo untuk tiga kejadian uji: (a) kejadian eq_48801 pada Stasiun LWA, 25 Januari 2019 (prediksi *Large*, 0,66); (b) kejadian eq_62245 pada Stasiun LWA, 10 Agustus 2020 (prediksi *Large*, 0,60); dan (c) kejadian eq_62245 pada Stasiun KPY, 16 Agustus 2020 (prediksi *Large*, 0,49). Setiap baris menampilkan *overlay* pada ketiga kanal komponen geomagnetik, yaitu *Blended* Ch H, Ch D, dan Ch Z.

Pada Gambar 12(a) (kejadian eq_48801, Stasiun LWA), model memprediksi kelas *Large* dengan keyakinan relatif tinggi (0,66), dan aktivasi Grad-CAM terkonsentrasi secara tegas di bagian tengah *scalogram* pada rentang indeks waktu sekitar 150–300 dengan pita frekuensi menengah. Pada Gambar 12(b) (kejadian eq_62245, Stasiun LWA), aktivasi justru terpusat di sisi kiri *scalogram* (indeks waktu ± 100 –150) pada pita frekuensi yang lebih rendah, dengan keyakinan kelas *Large* sebesar 0,60. Sementara itu, pada Gambar 12(c) (kejadian eq_62245, Stasiun KPY), wilayah aktivasi bergeser ke sisi kanan (indeks waktu ± 300) dan ke pita frekuensi yang lebih tinggi, disertai keyakinan yang rendah dan ambigu, di mana probabilitas kelas *Large* (0,49) nyaris seimbang dengan kelas *Medium* (0,45).

Perbandingan ketiga kasus tersebut mengungkap satu temuan penting: wilayah *scalogram* yang dianggap penting oleh model berpindah-pindah secara signifikan antar-kejadian, tanpa adanya penanda spasial yang konsisten yang menjadi ciri khas suatu tingkat magnitudo. Hal ini paling jelas terlihat pada Gambar 12(b) dan 12(c), yang berasal dari kejadian yang sama (eq_62245) namun diamati pada stasiun dan jendela waktu berbeda: meskipun keduanya menghasilkan prediksi kelas yang sama (*Large*), fokus aktivasi dan tingkat keyakinannya jauh berbeda (0,60 pada Stasiun LWA berbanding 0,49 pada Stasiun KPY), bahkan dengan lokasi wilayah panas yang berlawanan sisi. Sebagai pembandingan, *overlay* untuk *head* prekursor cenderung menyoroti wilayah yang relatif stabil dan konsisten antar-kejadian, sejalan dengan tingginya akurasi deteksi prekursor. Perlu dicatat pula bahwa ketidakkonsistenan ini terjadi antar-kejadian, bukan antar-kanal, karena pola aktivasi pada ketiga komponen (H, D, Z) dalam satu kejadian relatif serupa.

E. Diskusi

Secara keseluruhan, hasil penelitian ini memperlihatkan pola yang konsisten di seluruh tahap evaluasi: model bekerja sangat baik pada tugas deteksi prekursor namun terbatas pada estimasi magnitudo. Pada tahap pelatihan, *head* prekursor konvergen cepat dan stabil pada akurasi validasi 0,90–0,92, sementara akurasi validasi *head* magnitudo tertahan di kisaran 0,50 meskipun akurasi pelatihannya terus meningkat. Pola ini berlanjut konsisten pada pengujian *blind test*, di mana *head* prekursor mencapai akurasi 0,8838 dengan kinerja seimbang antar-kelas, sedangkan *head* magnitudo hanya mencapai akurasi 0,5267 dengan *macro-F1* 0,3253 dan kecenderungan kuat memprediksi kelas mayoritas *Moderate*. Interpretasi Grad-CAM kemudian memberikan penjelasan visual atas kontras tersebut: aktivasi *head* prekursor terlokalisasi secara konsisten antar-stasiun, sementara

aktivasi *head* magnitudo berpindah-pindah tanpa penanda spasial yang tetap antar-kejadian.

Temuan tersebut memperkuat interpretasi terhadap rendahnya kinerja *head* magnitudo. Pergeseran wilayah aktivasi yang tidak menentu menunjukkan bahwa model belum berhasil mempelajari fitur pembeda magnitudo yang *invariant* dan dapat dipercaya, melainkan menyandarkan keputusannya pada pola lokal yang berbeda-beda untuk tiap kejadian. Dengan kata lain, rendahnya akurasi magnitudo bukan disebabkan oleh ketidakmampuan model "melihat" sinyal, tetapi oleh lemahnya keterkaitan yang konsisten antara fitur *scalogram* ULF dan tingkat magnitudo gempa. Hal ini sejalan dengan pemahaman fisis bahwa amplitudo anomali geomagnetik tidak berhubungan langsung dengan magnitudo, melainkan turut dipengaruhi faktor lain seperti jarak episentrum, kedalaman sumber, dan kondisi konduktivitas lokal sehingga informasi yang tersedia pada sinyal belum cukup untuk memetakan magnitudo secara andal.

Konsistensi keterbatasan ini lintas-arsitektur memperkuat kesimpulan bahwa kendala utama bukan terletak pada pemilihan arsitektur model, melainkan pada keterbatasan informasi pembeda magnitudo yang terkandung dalam sinyal ULF itu sendiri, diperberat oleh ketidakseimbangan distribusi kelas. Dengan demikian, kontribusi utama penelitian ini adalah menunjukkan bahwa pendekatan ResNet *multi-task* multi-stasiun berbasis *scalogram* sangat menjanjikan untuk deteksi prekursor sebagai komponen inti sistem peringatan dini, sekaligus memetakan secara jujur batas kemampuan estimasi magnitudo berbasis sinyal ULF sebagai arah yang masih memerlukan pengembangan lebih lanjut.

IV. KESIMPULAN/RINGKASAN

Berdasarkan hasil analisis data dan evaluasi performa model, dapat disimpulkan bahwa pendekatan yang digunakan dalam penelitian ini menunjukkan kinerja yang efektif dalam membangun sistem deteksi dini gempa berbasis sinyal geomagnetik. Model *deep learning* berbasis *Residual Neural Network* (ResNet-18) dengan pendekatan *multi-task learning* berhasil dikembangkan dan mampu menjalankan dua tugas secara simultan, yaitu mendeteksi keberadaan prekursor gempa serta mengestimasi kelas magnitudo, dengan memanfaatkan representasi *scalogram* hasil transformasi *Continuous Wavelet Transform* dari sinyal *Ultra Low Frequency* (ULF). Beberapa hal yang penting diperhatikan oleh penulis:

1. Model *multi-task* yang dikembangkan mampu mendeteksi keberadaan prekursor gempa dengan kinerja yang tinggi dan stabil, yaitu akurasi sebesar 88,25% dengan nilai *precision* dan *recall* yang seimbang pada kedua kelas. Hal ini menunjukkan bahwa representasi *scalogram* dari sinyal ULF memuat pola pembeda yang konsisten, sebagaimana diperkuat oleh interpretasi Grad-CAM yang menyoroti wilayah aktivasi yang stabil dan konsisten antar-stasiun.
2. Pada tugas estimasi magnitudo, model mampu memprediksi tiga kelas magnitudo (*Moderate*, *Medium*, dan *Large*) dengan akurasi sebesar 52,67%. Analisis lebih lanjut menunjukkan bahwa keterbatasan kinerja ini bersumber dari ketidakseimbangan distribusi kelas serta lemahnya

keterkaitan langsung antara amplitudo anomali geomagnetik dan magnitudo gempa, sebagaimana tercermin dari pola aktivasi Grad-CAM yang berpindah-pindah antar-kejadian. Dengan demikian, kemampuan deteksi prekursor model dapat diandalkan sebagai komponen inti sistem peringatan dini, sementara estimasi magnitudo telah berfungsi sebagai dasar yang menjanjikan untuk pengembangan selanjutnya.

Adapun saran untuk pengembangan penelitian ke depan adalah sebagai berikut:

1. Mengembangkan model agar tidak hanya mengestimasi prekursor dan magnitudo, tetapi juga arah datang gempa (*azimuth*), sehingga estimasi parameter gempa menjadi lebih lengkap untuk kebutuhan sistem peringatan dini.
2. Meningkatkan akurasi estimasi magnitudo, antara lain melalui penanganan ketidakseimbangan kelas (misalnya *class weighting*, *focal loss*, atau penambahan sampel kelas *Large*), serta penambahan fitur fisis pendukung seperti jarak episentrum, kedalaman sumber, dan rasio Z/H ke dalam *magnitude head*.

UCAPAN TERIMA KASIH

Penulis J.A.L. mengucapkan terima kasih kepada dosen pembimbing atas bimbingan dan arahnya selama penelitian, serta kepada Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) yang telah menyediakan data geomagnetik dan katalog gempa yang digunakan dalam penelitian ini. Penulis juga menyampaikan terima kasih kepada Departemen Teknik Fisika, Institut Teknologi Sepuluh Nopember, atas dukungan fasilitas selama pelaksanaan penelitian.

DAFTAR PUSTAKA

- [1] BMKG, *Laporan Kinerja 2022 Badan Meteorologi, Klimatologi, dan Geofisika*. Jakarta: BMKG (2022).
- [2] R. M. Allen and D. Melgar, "Earthquake early warning: Advances, scientific challenges, and societal needs," *Annu. Rev. Earth Planet. Sci.*, Vol. 47 (2019) 361–388.
- [3] S. M. Mousavi, W. L. Ellsworth, W. Zhu, L. Y. Chuang, and G. C. Beroza, "Earthquake transformer—an attentive deep-learning model for simultaneous earthquake detection and phase picking," *Nat. Commun.*, Vol. 11 (2020), doi: 10.1038/s41467-020-17591-w.
- [4] K. Hattori and M. Hayakawa, "Ultra-low-frequency electromagnetic emissions associated with earthquakes," *IEEJ Trans. Fundam. Mater.*, Vol. 124 (2004) 1101, doi: 10.1541/ieejfms.124.1101.
- [5] E. M. Takla and A. Yoshikawa, "ULF signals as earthquake precursors in various tectonic regions," *Discover Geoscience*, Vol. 4 (2026), doi: 10.1007/s44288-026-00386-9.
- [6] U. Wahyuningsih, S. Rasimeng, and K. Karyanto, "Analisis anomali sinyal ultra low frequency

berdasarkan data pengukuran geomagnetik sebagai indikator prekursor gempabumi wilayah Lampung tahun 2016," *JGE (Jurnal Geofisika Eksplorasi)*, Vol. 4, No. 2 (2020) 187–200, doi: 10.23960/jge.v4i2.16.

- [7] Z. Li, F. Liu, W. Yang, S. Peng, and J. Zhou, "A survey of convolutional neural networks: Analysis, applications, and prospects," *IEEE Trans. Neural Netw. Learn. Syst.*, Vol. 33, No. 12 (2022) 6999–7019, doi: 10.1109/TNNLS.2021.3084827.
- [8] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)* (2016) 770–778, doi: 10.1109/CVPR.2016.90.
- [9] O. A. Molchanov and M. Hayakawa, *Seismo-Electromagnetics and Related Phenomena*. Tokyo: Terra Scientific Publishing (2008).
- [10] M. Hayakawa, *Earthquake Prediction with Radio Techniques*. Singapore: John Wiley & Sons (2015).
- [11] K. Yumoto and the MAGDAS Group, "MAGDAS project and its application for space weather and earthquake studies," *Earth, Planets and Space* (2009).
- [12] J. Zhang, K. Sun, X. Han, and N. Mao, "Application of machine learning models to multi-parameter maximum magnitude prediction," *Applied Sciences*, Vol. 14 (2024), doi: 10.3390/app142411854.

